く Linux性能优化实战 首页 | Q

# 26 | 案例篇:如何找出狂打日志的"内鬼"?

2019-01-18 倪朋飞



讲述:冯永吉

时长 12:37 大小 11.56M



你好,我是倪朋飞。

前两节,我们学了文件系统和磁盘的 I/O 原理,我先带你复习一下。

文件系统,是对存储设备上的文件进行组织管理的一种机制。为了支持各类不同的文件系统,Linux 在各种文件系统上,抽象了一层虚拟文件系统 VFS。

它定义了一组所有文件系统都支持的数据结构和标准接口。这样,应用程序和内核中的其他子系统,就只需要跟 VFS 提供的统一接口进行交互。

在文件系统的下层,为了支持各种不同类型的存储设备,Linux 又在各种存储设备的基础上,抽象了一个通用块层。

通用块层,为文件系统和应用程序提供了访问块设备的标准接口;同时,为各种块设备的驱动程序提供了统一的框架。此外,通用块层还会对文件系统和应用程序发送过来的 I/O 请求进行排队,并通过重新排序、请求合并等方式,提高磁盘读写的效率。

通用块层的下一层,自然就是设备层了,包括各种块设备的驱动程序以及物理存储设备。

文件系统、通用块层以及设备层,就构成了 Linux 的存储 I/O 栈。存储系统的 I/O ,通常是整个系统中最慢的一环。所以, Linux 采用多种缓存机制,来优化 I/O 的效率,比方说,

为了优化文件访问的性能,采用页缓存、索引节点缓存、目录项缓存等多种缓存机制,减少对下层块设备的直接调用。

同样的,为了优化块设备的访问效率,使用缓冲区来缓存块设备的数据。

不过,在碰到文件系统和磁盘的 I/O 问题时,具体应该怎么定位和分析呢?今天,我就以一个最常见的应用程序记录大量日志的案例,带你来分析这种情况。

## 案例准备

本次案例还是基于 Ubuntu 18.04,同样适用于其他的 Linux 系统。我使用的案例环境如下所示:

机器配置: 2 CPU, 8GB 内存

预先安装 docker、sysstat 等工具,如 apt install docker.io sysstat

这里要感谢唯品会资深运维工程师阳祥义帮忙,分担了今天的案例。这个案例,是一个用 Python 开发的小应用,为了方便运行,我把它打包成了一个 Docker 镜像。这样,你只要 运行 Docker 命令,就可以启动它。

接下来,打开一个终端,SSH 登录到案例所用的机器中,并安装上述工具。跟以前一样,案例中所有命令,都默认以 root 用户运行。如果你是用普通用户身份登陆系统,请运行sudo su root 命令,切换到 root 用户。

到这里,准备工作就完成了。接下来,我们正式进入操作环节。

温馨提示:案例中 Python 应用的核心逻辑比较简单,你可能一眼就能看出问题,但实际生产环境中的源码就复杂多了。所以,我依旧建议,操作之前别看源码,避免先入为主,要把它当成一个黑盒来分析。这样,你可以更好把握住,怎么从系统的资源使用问题出发,分析出瓶颈所在的应用,以及瓶颈在应用中大概的位置。

## 案例分析

首先,我们在终端中执行下面的命令,运行今天的目标应用:

■复制代码

1 \$ docker run -v /tmp:/tmp --name=app -itd feisky/logapp

然后,在终端中运行 ps 命令,确认案例应用正常启动。如果操作无误,你应该可以在 ps 的输出中,看到一个 app.py 的进程:

■复制代码

```
1 $ ps -ef | grep /app.py
```

2 root 18940 18921 73 14:41 pts/0 00:00:02 python /app.py

接着,我们来看看系统有没有性能问题。要观察哪些性能指标呢?前面文章中,我们知道 CPU、内存和磁盘 I/O 等系统资源,很容易出现资源瓶颈,这就是我们观察的方向了。我们来观察一下这些资源的使用情况。

当然, 动手之前你应该想清楚, 要用哪些工具来做, 以及工具的使用顺序又是怎样的。你可以先回忆下前面的案例和思路, 自己想一想, 然后再继续下面的步骤。

我的想法是,我们可以先用 top ,来观察 CPU 和内存的使用情况;然后再用 iostat ,来观察磁盘的 I/O 情况。

所以,接下来,你可以在终端中运行 top 命令,观察 CPU 和内存的使用情况:

■复制代码

```
3 top - 14:43:43 up 1 day, 1:39, 2 users, load average: 2.48, 1.09, 0.63
4 Tasks: 130 total, 2 running, 74 sleeping, 0 stopped,
5 %Cpu0 : 0.7 us, 6.0 sy, 0.0 ni, 0.7 id, 92.7 wa, 0.0 hi, 0.0 si, 0.0 st
6 %Cpu1 : 0.0 us, 0.3 sy, 0.0 ni, 92.3 id, 7.3 wa, 0.0 hi, 0.0 si, 0.0 st
7 KiB Mem : 8169308 total, 747684 free, 741336 used, 6680288 buff/cache
8 KiB Swap:
                0 total,
                              0 free,
                                            0 used. 7113124 avail Mem
10
   PID USER
                PR NI VIRT RES SHR S %CPU %MEM
                                                       TIME+ COMMAND
11 18940 root
               20 0 656108 355740 5236 R 6.3 4.4 0:12.56 python
12 1312 root
              20 0 236532 24116 9648 S 0.3 0.3 9:29.80 python3
```

观察 top 的输出,你会发现,CPU0的使用率非常高,它的系统CPU使用率(sys%)为6%,而 iowait 超过了90%。这说明CPU0上,可能正在运行I/O密集型的进程。不过,究竟是什么原因呢?这个疑问先保留着,我们先继续看完。

接着我们来看,进程部分的 CPU 使用情况。你会发现, python 进程的 CPU 使用率已经达到了 6%,而其余进程的 CPU 使用率都比较低,不超过 0.3%。看起来 python 是个可疑进程。记下 python 进程的 PID 号 18940,我们稍后分析。

最后再看内存的使用情况,总内存 8G,剩余内存只有730 MB,而 Buffer/Cache 占用内存高达6GB之多,这说明内存主要被缓存占用。虽然大部分缓存可回收,我们还是得了解下缓存的去处,确认缓存使用都是合理的。

到这一步,你基本可以判断出,CPU 使用率中的 iowait 是一个潜在瓶颈,而内存部分的缓存占比较大,那磁盘 I/O 又是怎么样的情况呢?

我们在终端中按 Ctrl+C ,停止 top 命令,再运行 iostat 命令,观察 I/O 的使用情况:

■复制代码

```
1 # -d 表示显示 I/O 性能指标, -x 表示显示扩展统计(即所有 I/O 指标)
2  $ iostat -x -d 1
3 Device
                r/s
                      w/s
                              rkB/s
                                      wkB/s
                                             rrqm/s
                                                     wrqm/s %rrqm %wrqm r awai
4 loop0
                0.00
                      0.00
                             0.00
                                      0.00
                                               0.00
                                                       0.00
                                                            0.00
                                                                  0.00
                                                                         0.0
                0.00
                     0.00
5 sdb
                              0.00
                                       0.00
                                               0.00
                                                       0.00
                                                            0.00
                                                                  0.00
                                                                         0.0
                0.00
                     64.00
                             0.00 32768.00
                                               0.00
                                                       0.00
                                                            0.00
                                                                  0.00
6 sda
                                                                         0.0
```

还记得这些性能指标的含义吗?先自己回忆一下,如果实在想不起来,查看上一节的内容,或者用 man iostat 查询。

观察 iostat 的最后一列,你会看到,磁盘 sda 的 I/O 使用率已经高达 99%,很可能已经接近 I/O 饱和。

再看前面的各个指标,每秒写磁盘请求数是 64,写大小是 32 MB,写请求的响应时间为7秒,而请求队列长度则达到了 1100。

超慢的响应时间和特长的请求队列长度,进一步验证了 I/O 已经饱和的猜想。此时,sda 磁盘已经遇到了严重的性能瓶颈。

到这里,也就可以理解,为什么前面看到的 iowait 高达 90% 了,这正是磁盘 sda 的 I/O 瓶颈导致的。接下来的重点就是分析 I/O 性能瓶颈的根源了。那要怎么知道,这些 I/O 请求相关的进程呢?

不知道你还记不记得,上一节我曾提到过,可以用 pidstat 或者 iotop ,观察进程的 I/O 情况。这里,我就用 pidstat 来看一下。

使用 pidstat 加上 -d 参数,就可以显示每个进程的 I/O 情况。所以,你可以在终端中运行如下命令来观察:

■复制代码

1	<pre>\$ pidstat -d 1</pre>							
2								
3	15:08:35	UID	PID	kB_rd/s	kB_wr/s	kB_ccwr/s	iodelay	Command
4	15:08:36	0	18940	0.00	45816.00	0.00	96	python
5								
6	15:08:36	UID	PID	kB_rd/s	kB_wr/s	kB_ccwr/s	iodelay	Command
7	15:08:37	0	354	0.00	0.00	0.00	350	jbd2/sda1-8
8	15:08:37	0	18940	0.00	46000.00	0.00	96	python
9	15:08:37	0	20065	0.00	0.00	0.00	1503	kworker/u4:2

从 pidstat 的输出,你可以发现,只有 python 进程的写比较大,而且每秒写的数据超过 45 MB,比上面 iostat 发现的 32MB 的结果还要大。很明显,正是 python 进程导致了 I/O 瓶颈。

再往下看 iodelay 项。虽然只有 python 在大量写数据,但你应该注意到了,有两个进程(kworker 和 jbd2 )的延迟,居然比 python 进程还大很多。

这其中,kworker是一个内核线程,而jbd2是 ext4文件系统中,用来保证数据完整性的内核线程。他们都是保证文件系统基本功能的内核线程,所以具体细节暂时就不用管了,我们只需要明白,它们延迟的根源还是大量 I/O。

综合 pidstat 的输出来看,还是 python 进程的嫌疑最大。接下来,我们来分析 python 进程到底在写什么。

首先留意一下 python 进程的 PID 号 , 18940。看到 18940 , 你有没有觉得熟悉 ? 其实前面在使用 top 时 , 我们记录过的 CPU 使用率最高的进程 , 也正是它。不过 , 虽然在 top 中使用率最高 , 也不过是 6% , 并不算高。所以 , 以 I/O 问题为分析方向还是正确 的。

知道了进程的 PID 号, 具体要怎么查看写的情况呢?

其实,我在系统调用的案例中讲过,读写文件必须通过系统调用完成。观察系统调用情况,就可以知道进程正在写的文件。想起 strace 了吗,它正是我们分析系统调用时最常用的工具。

接下来, 我们在终端中运行 strace 命令, 并通过-p 18940 指定 python 进程的 PID 号:

■复制代码

```
1 $ strace -p 18940
2 strace: Process 18940 attached
3 ...
4 mmap(NULL, 314576896, PROT_READ|PROT_WRITE, MAP_PRIVATE|MAP_ANONYMOUS, -1, 0) = 0x7f0f7a
5 mmap(NULL, 314576896, PROT_READ|PROT_WRITE, MAP_PRIVATE|MAP_ANONYMOUS, -1, 0) = 0x7f0f68
6 write(3, "2018-12-05 15:23:01,709 - __main"..., 314572844
7 ) = 314572844
8 munmap(0x7f0f682e8000, 314576896) = 0
9 write(3, "\n", 1) = 1
10 munmap(0x7f0f7aee9000, 314576896) = 0
11 close(3) = 0
12 stat("/tmp/logtest.txt.1", {st_mode=S_IFREG|0644, st_size=943718535, ...}) = 0
```

◀

从 write() 系统调用上,我们可以看到,进程向文件描述符编号为 3 的文件中,写入了 300MB 的数据。看来,它应该是我们要找的文件。不过,write()调用中只能看到文件的描述符编号,文件名和路径还是未知的。

再观察后面的 stat() 调用,你可以看到,它正在获取/tmp/logtest.txt.1 的状态。 这种"点+数字格式"的文件,在日志回滚中非常常见。我们可以猜测,这是第一个日志回滚文件,而正在写的日志文件路径,则是/tmp/logtest.txt。

当然,这只是我们的猜测,自然还需要验证。这里,我再给你介绍一个新的工具 lsof。它专门用来查看进程打开文件列表,不过,这里的"文件"不只有普通文件,还包括了目录、块设备、动态库、网络套接字等。

接下来,我们在终端中运行下面的 lsof 命令,看看进程 18940 都打开了哪些文件:

■复制代码

```
1 $ lsof -p 18940
2 COMMAND PID USER FD TYPE DEVICE SIZE/OFF NODE NAME
3 python 18940 root cwd DIR 0,50 4096 1549389 /
4 python 18940 root rtd DIR 0,50 4096 1549389 /
5 ...
6 python 18940 root 2u CHR 136,0 0t0 3 /dev/pts/0
7 python 18940 root 3w REG 8,1 117944320 303 /tmp/logtest.txt
```

这个输出界面中,有几列我简单介绍一下,FD表示文件描述符号,TYPE表示文件类型,NAME表示文件路径。这也是我们需要关注的重点。

再看最后一行,这说明,这个进程打开了文件 /tmp/logtest.txt , 并且它的文件描述符是 3 号 , 而 3 后面的 w , 表示以写的方式打开。

这跟刚才 strace 完我们猜测的结果一致,看来这就是问题的根源:进程 18940 以每次 300MB 的速度,在"疯狂"写日志,而日志文件的路径是 /tmp/logtest.txt。

既然找出了问题根源,接下来按照惯例,就该查看源代码,然后分析为什么这个进程会狂打日志了。

你可以运行 docker cp 命令,把案例应用的源代码拷贝出来,然后查看它的内容。(你也可以点击这里查看案例应用的源码):

**目**复制代码

```
1 # 拷贝案例应用源代码到当前目录
2 $ docker cp app:/app.py .
4 # 查看案例应用的源代码
5 $ cat app.py
7 logger = logging.getLogger(__name__)
8 logger.setLevel(level=logging.INFO)
9 rHandler = RotatingFileHandler("/tmp/logtest.txt", maxBytes=1024 * 1024 * 1024, backupCo
10 rHandler.setLevel(logging.INFO)
11
12 def write_log(size):
   '''Write logs to file'''
13
   message = get_message(size)
   while True:
15
     logger.info(message)
16
     time.sleep(0.1)
17
18
19 if __name__ == '__main__':
   msg size = 300 * 1024 * 1024
   write_log(msg_size)
21
```

分析这个源码,我们发现,它的日志路径是/tmp/logtest.txt,默认记录 INFO 级别以上的所有日志,而且每次写日志的大小是 300MB。这跟我们上面的分析结果是一致的。

一般来说,生产系统的应用程序,应该有动态调整日志级别的功能。继续查看源码,你会发现,这个程序也可以调整日志级别。如果你给它发送 SIGUSR1 信号,就可以把日志调整为 INFO 级;发送 SIGUSR2 信号,则会调整为 WARNING 级:

■ 复制代码

```
def set_logging_info(signal_num, frame):
    '''Set loging level to INFO when receives SIGUSR1'''
    logger.setLevel(logging.INFO)

def set_logging_warning(signal_num, frame):
    '''Set loging level to WARNING when receives SIGUSR2'''
    logger.setLevel(logging.WARNING)

signal.signal(signal.SIGUSR1, set logging info)
```

10 signal.signal(signal.SIGUSR2, set\_logging\_warning)

根据源码中的日志调用 logger. info(message) ,我们知道 ,它的日志是 INFO 级 ,这也正是它的默认级别。那么 ,只要把默认级别调高到 WARNING 级 ,日志问题应该就解决了。

接下来,我们就来检查一下,刚刚的分析对不对。在终端中运行下面的 kill 命令,给进程 18940 发送 SIGUSR2 信号:

■复制代码

1 \$ kill -SIGUSR2 18940

#### 然后, 再执行 top 和 iostat 观察一下:

■复制代码

```
1 $ top
2 ...
3 %Cpu(s): 0.3 us, 0.2 sy, 0.0 ni, 99.5 id, 0.0 wa, 0.0 hi, 0.0 si, 0.0 st
```

■复制代码

```
1 $ iostat -d -x 1
2 Device
                r/s
                      W/S
                             rkB/s
                                       wkB/s rrqm/s
                                                    wrqm/s %rrqm %wrqm r awai
3 loop0
                0.00
                      0.00
                              0.00
                                       0.00
                                               0.00
                                                       0.00
                                                            0.00
                                                                  0.00
                                                                         0.0
4 sdb
                0.00
                     0.00
                              0.00
                                        0.00
                                               0.00
                                                       0.00 0.00
                                                                   0.00
                                                                          0.0
5 sda
                0.00
                       0.00
                               0.00
                                        0.00
                                               0.00
                                                       0.00
                                                             0.00
                                                                   0.00
                                                                          0.0
```

观察 top 和 iostat 的输出,你会发现,稍等一段时间后,iowait 会变成 0,而 sda 磁盘的 I/O 使用率也会逐渐减少到 0。

到这里,我们不仅定位了狂打日志的应用程序,并通过调高日志级别的方法,完美解决了 I/O 的性能瓶颈。

案例最后,当然不要忘了运行下面的命令,停止案例应用:

#### 小结

日志,是了解应用程序内部运行情况,最常用、也最有效的工具。无论是操作系统,还是应用程序,都会记录大量的运行日志,以便事后查看历史记录。这些日志一般按照不同级别来开启,比如,开发环境通常打开调试级别的日志,而线上环境则只记录警告和错误日志。

在排查应用程序问题时,我们可能需要,在线上环境临时开启应用程序的调试日志。有时候,事后一不小心就忘了调回去。没把线上的日志调高到警告级别,可能会导致 CPU 使用率、磁盘 I/O 等一系列的性能问题,严重时,甚至会影响到同一台服务器上运行的其他应用程序。

今后,在碰到这种"狂打日志"的场景时,你可以用 iostat、strace、Isof 等工具来定位 狂打日志的进程,找出相应的日志文件,再通过应用程序的接口,调整日志级别来解决问 题。

如果应用程序不能动态调整日志级别,你可能还需要修改应用的配置,并重启应用让配置生效。

## 思考

最后,给你留一个思考题。

在今天的案例开始时,我们用 top 和 iostat 查看了系统资源的使用情况。除了 CPU 和磁盘 I/O 外,剩余内存也比较少,而内存主要被 Buffer/Cache 占用。

那么,今天的问题就是,这些内存到底是被 Buffer 还是 Cache 占用了呢?有没有什么方法来确认你的分析结果呢?

欢迎在留言区和我讨论,也欢迎把这篇文章分享给你的同事、朋友。我们一起在实战中演练,在交流中进步。



© 版权归极客邦科技所有,未经许可不得转载

上一篇 25 | 基础篇: Linux 磁盘I/O是怎么工作的(下)

下一篇 27 | 案例篇: 为什么我的磁盘I/O延迟很高?

## 精选留言 (18)





**1**1

大神,能问一个题外话吗,关于自己人生规划,水平和眼界所限,想不通,都说大神级见识很广也多,能给我这个35岁只维护过四五十台linux服务器的运维指条路吗?

现在很迷茫和压力大~~

能力如下:...

展开~

作者回复: 看前面的经历, 技术面还是挺广的, 但可能很多地方都不太深入。

建议还是先找份工作吧,长期待业可能会加重焦虑。然后可以根据实际工作需要,先把工作需要的知识技能加深掌握。等到可以从容应对工作的时候,再考虑在某个领域加强深入。

凸 6

pcstat(page cache stat)这个可以查看目标log文件在cache中的大小展开~

作者回复: 嗯嗯 是的,并且这个工具需要知道哪个文件

**郭江伟** 2019-01-18

**心** 4

buffers/cached使用情况可以从proc文件系统看:

gjw@gjw:~\$ cat /proc/meminfo

MemTotal: 7588504 kB MemFree: 3621800 kB

MemAvailable: 6335912 kB...

展开٧

**划时代** 2019-01-18

**ြ** 3

指出老师的一个问题,"日志回滚文件",打印日志的过程中从直觉来看很容易误认为日志是在"回滚",我也犯过这样的错误;rotating英文直译为"旋转"或"轮流",实际的日志打印过程中,日志名称是"旋转"的,例如log.1(当前打印的日志文件并且一直会打印这个文件),log.2(较早日志),log.3(更早日志),当触发"旋转"条件时,日志名称会发生变更,假如log.3是上限数,那么log.3发生"旋转"就被remove,log.2被rename...

作者回复: 谢谢指出,确实只是文件名称的旋转,内容并没有回滚

Geek\_41dcb...
2019-01-18

**1** 2

在回答今天的思考题前,我想需要明确两个前提,一个是Buffer到底在整个系统结构的哪一层,会不会是不是在IO调度器的下一层,我想应该会,理由是Buffer缓存磁盘内容调度

器合并后再去写磁盘效率更好;另一个是之前有看到留言对于文件系统使用带Cache的IO操作底层为了性能Buffer和Cache是合并的,如果是这样那我就从逻辑上认为它们是分开的,这样好回答问题(声明我没看过底层代码都是没有代码依据的)。 我认为增长的地方… 展开 >

作者回复: 嗯 可以实际操作验证一下





2019-01-20

logger.info(message)的情况下,还可以使用logger.setLevel修改日志级别吗? 展开~

作者回复: 可以的,比如调高到警告级别,那么 info()实际上就不写了



**心**1

**心**1

[D26打卡]

又是老套路了,哈哈。

先是top看%iowait到升高,再看pidstat是哪个进程在操作磁盘,再strace看进程的调用 栈。

看/proc/meminfo就可以看到系统的buffer和cache各占了多少吧。前后一对比就知道… 展开~



wtcctw

2019-01-18

凸 1

逻辑清晰,步骤详细,赞

展开~



凸

打卡

展开٧



לאו

老师,这些docker镜像什么地方下载

展开٧

作者回复: 直接 docker pull 就可以下载,源代码在 github 上面: https://github.com/feiskyer/linux-perf-examples

无名老卒

மி

2019-01-22

查看buffer/cache占用,建议使用pcstat或者hcache, hcache是基于pcstat的, pcstat 可以查看某个文件是否被缓存和根据进程pid来查看都缓存了哪些文件。hcache在其基础 上增加了查看整个操作系统Cache和根据使用Cache大小排序的特性。

[root@linjx ~]# hcache --top 3...

展开٧



xfan

凸

我开启了交换swap,和实验不同的是我的Buffer/cache占用不高,反倒是swap很高。还 有一个是基本没有写,读很高。奇怪

作者回复: 检查下swapiness的设置

凸

渡渡鸟\_lin...

2019-01-21

我这边使用centos7 2c 8g 实验结果与文章中有些区别:

- 1. 在运行容器后,使用top命令发现sys与iowait各占单个CPU的10-50%
- 2. 针对iowait, 使用dstat发现磁盘每秒写入约为300M; vmstat中bo也验证了写请求较大
- 3. 使用pidstat -d 分析发现是Python写入请求大,根据 iostat分析到当前磁盘使用率 90%,写队列1000...

展开~

作者回复: sys使用高是正常的,任何IO都要经过系统调用完成,自然要占用sys。



#### 小老鼠

2019-01-20

凸

我觉的应该是cache,写日志,日志是文件

展开٧



#### 仲鬼

2019-01-18

"每秒写的数据超过 45 MB,比上面 iostat 发现的 32MB 的结果还要大"老师好,没明白这里的比较要说明什么问题?

作者回复: 这儿是要说 IO 的来源, 肯定是 I/O 大的进程



#### 安小依

2019-01-18



Ubuntu 16.04, 使用 strace 应该需要先临时修改系统一个配置: echo 0 | sudo tee /proc/sys/kernel/yama/ptrace\_scope。另外用 java 模拟写文件, strace 发现还是不行, 一直卡在这个地方:

zk@zk-pc:~/Documents\$ strace -p 6526...

展开~

作者回复: 你这个例子是向文件 /tmp/aaa 写 , 不是标准输出



#### 唯美

2019-01-18



打卡Day26 day day up!



# 打卡day27

应该是被cache占用,因为内存篇提到cache主要是负责文件的读写缓存,buffer是负责块设备读写缓存,而案例中写的是文件可以通过cachestat验证